

CLASSIFICAÇÃO DA QUALIDADE DE VINHOS TINTOS COM APRENDIZADO DE MÁQUINA

**Aplicação de Regressão Logística,
Random Forest e SVC com PCA**

Fernando Laguzza

Escola Politécnica de Pernambuco — Universidade de
Pernambuco

Disciplina: Inteligência Artificial — 2026

O QUE ESTE TRABALHO PROPÕE?

- Aplicar algoritmos de **classificação supervisionada** para prever a qualidade de vinhos tintos
- Comparar o desempenho de três algoritmos: **Logistic Regression, Random Forest** e **SVC**
- Utilizar **PCA** para redução de dimensionalidade e **Grid Search** para otimização de hiperparâmetros
- Avaliar os modelos com métricas robustas: Accuracy, Precision, Recall, F1-Score, ROC/AUC

AVALIAÇÃO DE QUALIDADE: DO ESPECIALISTA AO ALGORITMO

MÉTODO TRADICIONAL

-  Análise sensorial por especialistas
-  Subjetivo e custoso
-  Difícil de replicar

MÉTODO COMPUTACIONAL

-  Análise de dados físico-químicos
-  Objetivo e escalável
-  Reprodutível e automatizável

APLICAÇÕES REAIS

- Controle de qualidade em vinícolas
- Monitoramento de processos produtivos
- Apoio à tomada de decisão na indústria vitivinícola

Fonte: Cortez et al. (2009) – Wine Quality Dataset, UCI Machine Learning Repository

1.599 AMOSTRAS DE VINHO TINTO PORTUGUÊS — VINHO VERDE

ORIGEM

UCI Machine Learning Repository
(Cortez et al., 2009)

DIMENSÕES

1.599 amostras (registros)
12 atributos (11 explicativas + 1 alvo)


QUALIDADE DOS DADOS

Sem valores nulos — sem necessidade de imputação.

VARIÁVEL	DESCRIÇÃO
fixed acidity	Acidez fixa
volatile acidity	Acidez volátil
citric acid	Ácido cítrico
residual sugar	Açúcar residual
chlorides	Cloretos
free / total sulfur dioxide	Dióxido de enxofre
density	Densidade
pH	pH
sulphates	Sulfatos
alcohol	Teor alcoólico
quality (target)	Nota de qualidade (3 a 8)

A QUALIDADE DO VINHO É DESBALANCEADA

DISTRIBUIÇÃO ORIGINAL



- Variável **quality** original: valores inteiros de **3 a 8**
- Notas **5 e 6** representam a grande maioria das amostras
- Notas **3 e 8** possuem pouquíssimas observações

RECATEGORIZAÇÃO PARA 3 CLASSES:

QUALIDADE ORIGINAL	CLASSE	RÓTULO
3 e 4	0	Bad
5 e 6	1	Middle
7 e 8	2	Good



O desbalanceamento impacta diretamente o desempenho dos modelos — classes minoritárias são mais difíceis de classificar.

OBJETIVO: COMPARAR ALGORITMOS SUPERVISIONADOS PARA CLASSIFICAÇÃO DE QUALIDADE

OBJETIVO GERAL

Aplicar e comparar Logistic Regression, Random Forest e SVC na classificação da qualidade de vinhos, com PCA, validação cruzada e otimização de hiperparâmetros.

OBJETIVOS ESPECÍFICOS

- Realizar Análise Exploratória dos Dados (EDA)
- Investigar relações entre variáveis físico-químicas e qualidade
- Pré-processar dados: padronização e recategorização da variável alvo
- Aplicar PCA para redução de dimensionalidade
- Treinar e otimizar os três modelos com Grid Search + Cross Validation
- Comparar modelos com métricas: Accuracy, Precision, Recall, F1-Score, ROC/AUC

PIPELINE COMPLETO: DA ANÁLISE EXPLORATÓRIA À AVALIAÇÃO

1 EDA

Análise exploratória: distribuição das classes, correlações entre variáveis.

2 PRÉ-PROCESSAMENTO

Recategorização da variável alvo (3 classes) + StandardScaler.

3 PCA

Redução de dimensionalidade (componentes: 5, 7 ou 9 — otimizado via Grid Search).

4 PIPELINE

StandardScaler → PCA → Classificador (estrutura unificada para todos os modelos).

5 GRID SEARCH + CV

Otimização automática de hiperparâmetros com 5-Fold Cross Validation.

6 AVALIAÇÃO

Conjunto de teste: Accuracy, Precision, Recall, F1-Score, Matriz de Confusão, ROC/AUC.



MOTIVAÇÃO: Correlações identificadas na EDA (ex: fixed acidity × pH, alcohol × density) motivaram o uso do PCA.

O DESBALANCEAMENTO DAS CLASSES É O PRINCIPAL DESAFIO

PRINCIPAIS ACHADOS DA EDA

- 🔍 Vinhos de maior qualidade tendem a ter: **maior teor alcoólico, mais sulfatos, mais ácido cítrico e menor acidez volátil.**

Correlações relevantes:

↑ alcohol ↑ qualidade

↓ volatile acidity ↓ qualidade

IMPACTO DO DESBALANCEAMENTO

- 📊 Todos os modelos classificaram melhor a classe **Middle** (mais amostras).
- ⚠️ Classes **Bad** e **Good** continuaram sendo as mais difíceis de identificar.
- 📊 Evidente nas matrizes de confusão e no AUC por classe.

RANDOM FOREST SUPERA OS DEMAIS EM TODAS AS MÉTRICAS PRINCIPAIS

MÉTRICA	LOGISTIC REGRESSION	SVC	RANDOM FOREST
ACCURACY (TREINO)	60,99%	71,54%	82,33%
ACCURACY (TESTE)	61,25%	68,13%	76,88%
PRECISION	0,846	0,840	0,834
RECALL	0,613	0,681	0,769
F1-SCORE	0,669	0,727	0,791



MELHORES HIPERPARÂMETROS (RANDOM FOREST)
n_estimators = 100 | max_depth = 5 | PCA = 7 componentes

BOA CAPACIDADE DISCRIMINATÓRIA EM TODOS OS MODELOS — DESTAQUE PARA A CLASSE MIDDLE

TABELA AUC POR CLASSE

MODELO	AUC — BAD	AUC — MIDDLE	AUC — GOOD
Logistic Regression	0,84	0,88	0,83
Random Forest	0,75	0,88	0,80
SVC	0,78	0,89	0,82

OBSERVAÇÕES

- ✓ Todos os modelos apresentaram $AUC > 0,7$ (desempenho aceitável a bom).
- ★ A classe **Middle** foi a mais bem discriminada ($AUC = 0,88$ em dois modelos).
- ⚠ A classe **Bad** foi a mais desafiadora para o Random Forest ($AUC = 0,75$).
- ↪ Diferença pequena entre acurácia de treino e teste indica **ausência de overfitting severo**.

RANDOM FOREST É O MODELO MAIS ADEQUADO

MACHINE LEARNING PODE SER ALTERNATIVA A AVALIAÇÃO SENSORIAL

-  O Random Forest obteve o melhor desempenho geral: ~77% de acurácia, F1-Score de 0,791
-  O SVC apresentou desempenho intermediário (68% de acurácia)
-  A Regressão Logística obteve o menor desempenho (61%), mas com estabilidade e sem overfitting
-  O PCA foi eficaz na redução de dimensionalidade, preservando a variabilidade dos dados
-  Técnicas de Machine Learning **podem auxiliar** a classificação de qualidade de vinhos a partir de propriedades físico-químicas

LIMITAÇÃO CENTRAL



O desbalanceamento das classes impactou o reconhecimento das categorias minoritárias.

OBRIGADO!

Fernando Laguzza

Escola Politécnica de Pernambuco — UPE

Disciplina de Inteligência Artificial — 2026

REFERÊNCIAS

JAMES et al. *An Introduction to Statistical Learning*. Springer, 2021.

CORTEZ et al. Wine preferences modeling by data mining. *Decision Support Systems*, v. 47, n. 4, p. 547–553, 2009.